EAE 6029

Exercícios sobre Modelos Lineares

No que segue, sempre suponha que as variáveis aleatória relevantes estão definidas no mesmo espaço de probabilidade.

Exercício 1 Seja Z uma variável aleatória discreta, que toma valores no conjunto $\{z_1, \ldots, z_n\}$; e Y uma variável aleatória com segundo momento finito. Defina o vetor aleatório $X = (\mathbf{1}_{\{z_2\}}(Z), \ldots \mathbf{1}_{\{z_n\}}(Z))$. Mostre que o melhor preditor linear de Y como função de um intercepto e X é da forma:

$$\alpha_* + \delta_*' X$$

com

$$\alpha_* = \mathbb{E}[Y|Z = z_1]$$
$$\delta_j = \mathbb{E}[Y|Z = z_{j+1}] - \mathbb{E}[Y|Z = z_1]$$

onde definimos o objeto $\mathbb{E}[Y|Z = z_j]$ como:

$$\mathbb{E}[Y|Z = z_j] := \frac{\mathbb{E}[Y\mathbf{1}_{\{z_j\}}(Z)]}{\mathbb{P}[\{Z = z_j\}]}.$$

. Conclua que o melhor preditor linear coincide com $\mathbb{E}[Y|Z]$.

Exercício 2 Seja h^* a função de esperança condicional de uma variável aleatória Y com segundo momento finito dado uma variável aleatória real X, i.e. $h^*(X) = \mathbb{E}[Y|X]$. Compute o melhor preditor linear de Y como função de um intercepto e X, para os casos abaixo. Ilustre graficamente a derivada de h^* comparando-a com a inclinação do melhor preditor linear, nos pontos do suporte[1] de X. Identifique as regiões onde o melhor preditor linear mais "erra" a inclinação de h^*.

a $h^*(x) = x^2$ e $X \sim U[0, 1]$.

b $h^*(x) = \min\{x^3, 100\}$ e $X \sim$ Exponecial(1).

c $h^*(x) = x^2$ e $X \sim \chi^2(1)$.

Exercício 3 Seja A uma matriz simétrica positiva semidefinida:

a Mostre que os autovalores de A sempre são não negativos. Dica: Se $v \neq 0$ é um autovetor de um autovalor λ, $Av = \lambda v$.

b Mostre que o menor autovalor de A é zero se, e somente se, existe $v \neq 0$, $v'Av = 0$. Dica: para suficiência, utilize a decomposição espectral de uma matriz simétrica.

[1] O suporte de uma variável aleatória X é definido como o menor conjunto fechado C tal que $\mathbb{P}[X \in C] = 1$.

Exercício 4 Seja $(\Omega, \Sigma, \mathbb{P})$ um espaço de probabilidade, em que cada elemento $\omega \in \Omega$ corresponde a uma firma num setor de interesse. Considere o exemplo, visto em aula, em que a função de produção no setor é $h(z, l) = zl^{\alpha}$, $\alpha < 1$. Suponha que, no momento da decisão de produção, uma firma $\omega \in \Omega$ na população somente observe um sinal $\xi(\omega)$ de sua produtividade. A distribuição do sinal ξ na população é denotada por $\mathbb{P}_{\xi}$. As firmas então escolhem l otimizando:

$$l(\omega) \in \text{argmax}_{l \geq 0}\, \xi(\omega) l^{\alpha} - wl\,,$$

onde w denota o salário (em unidades do bem produzido pelo setor), aqui tratado como constante fixa.[2] Após a escolha de demanda por trabalho, a produtividade de cada firma é revelada como $z(\omega) = \xi(\omega)\epsilon(\omega)$, onde o "choque" ou "surpresa" na produtividade não é antecipável com base no sinal, i.e. ξ é independente de ϵ ($\mathbb{P}_{(\xi,\epsilon)} = \mathbb{P}_{\xi} \otimes \mathbb{P}_{\epsilon}$). A produção final das firmas é dada por $Y(\omega) = z(\omega)l(\omega)$.

a Encontre o melhor preditor linear da variável aleatória $\log(Y)$ como função de um intercepto e $\log(l)$. O coeficiente associado a $\log(l)$ coincide com α? Por quê?

b Suponha que, caso $Y(\omega) - wl(\omega) < 0$, a firma ω não opera, e, nesse caso, a demanda por trabalho e quantidade produzida não são observadas. Calcule o melhor preditor linear nesse caso. Ele corresponde ao obtido anteriormente? Por quê?

Exercício 5: Interpretação do melhor preditor linear num modelo causal heterogêneo. Considere uma tripla de variáveis aleatórias (Y, D, X), definidas num espaço de probabilidade $(\Omega, \Sigma, \mathbb{P})$, em que a distribuição conjunta de (Y, D, X) reflete a distribuição em uma população de um resultado escalar (Y) de interesse, uma causa binária (D) de Y observável de interesse, e outras k causas observáveis (X) de Y sobre as quais não temos interesse direto. Nós definimos os resultados potenciais $Y(0)$ e $Y(1)$ correspondentes ao experimento hipótetico de se amostrar um elemento da população de interesse e fixar externamente sua causa D em 0 $(Y(0))$ ou 1 $(Y(1))$, mantidas as demais causas de Y, observáveis ou não, em seus valores originais. Com base nessa definição do modelo causal, segue que:

$$Y = Y(0) + D(Y(1) - Y(0))\,,$$

e a variável aleatória $\tau := Y(1) - Y(0)$ representa o efeito causal de D sobre uma unidade amostraao da população de interesse.

No que segue, nós vamos supor que, *condicionalmente a* X:

$$Y(0) \text{ é independente de } D\,,$$

isto é, para quaisquer eventos $A \in \mathcal{B}(\mathbb{R})$ e $B \in 2^{\{0,1\}}$:

$$\mathbb{P}[\{Y(0) \in A\} \cap \{D \in B\}|X] = \mathbb{P}[Y(0) \in A|X]\mathbb{P}[D \in B|X]$$

a Proveja uma interpretação para a hipótese de independência condicional apresentada acima.

[2] Em outras palavras, a incerteza capturada pelas variáveis aleatórias só se deve à amostragem no sentido clássico, e não à incerteza econômica.

b Mostre que, sob a hipótese de independência condicional apresentada acima, se $\mathbb{P}[D = 1|X](1 - \mathbb{P}[D = 1|X]) > 0$ quase certamente, e **ao menos uma** das duas condições abaixo for satisfeita:

i $\exists \psi \in \mathbb{R}^k$, $\mathbb{E}[Y(0)|X] = \psi' X$.

ii $\exists \phi \in \mathbb{R}^k$, $\mathbb{E}[D|X] = \phi' X$.

Então o coficiente β^* de D no melhor preditor linear de Y em D e X (com intercepto caso ele esteja incluso em X), definido como:

$$(\beta^*, \gamma^*) \in \operatorname{argmin}_{b \in \mathbb{R}, c \in \mathbb{R}^k} \mathbb{E}[(Y - Db - c'X)^2]$$

corresponderá a:

$$\beta^* = \frac{\mathbb{E}[\omega(X)\tau(X)]}{\mathbb{E}[\omega(X)]},$$

onde $\omega(X) = \mathbb{P}[D = 1|X](1 - \pi_*' X)$, com $\pi_* \in \operatorname{argmin}_{v \in \mathcal{R}^k} \mathbb{E}[(D - v'X)^2]$, e $\tau(X)$ é a variável aleatória que denota o efeito médio de tratamento na subpopulação tratada definida pelos valores de X, i.e.

$$\tau(X) \stackrel{\text{def}}{=} \mathbb{E}[(Y(1) - (0))|D = 1, X] = \frac{\mathbb{E}[(Y(1) - Y(0))D|X]}{\mathbb{P}[D = 1|X]}$$

Dica: use as condições de primeira ordem do melhor preditor linear para mostrar que:

$$\beta^* = \frac{\mathbb{E}[(D - \pi_*' X)Y]}{\mathbb{E}[(D - \pi_*' X)^2]},$$

onde você deve mostrar que $\mathbb{P}[D = 1|X](1 - \mathbb{P}[D = 1|X]) > 0$ q.c. implica que $\mathbb{E}[(D - \pi_*' X)^2] > 0$. Para concluir, você precisará mostrar que, sob a hipótese de independência condicional, se ao menos (i) ou (ii) vale, então:

$$\mathbb{E}[(D - \pi_*' X)Y(0)] = 0\,.$$

c Usando o resultado anterior, mostrar que:

$$\beta^* = \int \omega^*(x)\tau(x)\mathbb{P}_X(dx)\,,$$

onde $\mathbb{P}_X$ denota a lei de probabilidade induzida por X, e onde os **pesos** ω^* são tais que $\int \omega^*(x)\mathbb{P}_X(dx) = 1$, . Quando a condição (ii) é satisfeita, como esses pesos se comparam àqueles dados pelo efeito médio do tratamento na população tratada, definido como:

$$\tau^{\text{ATT}} \stackrel{\text{def}}{=} \mathbb{E}[(Y(1) - Y(0))|D = 1] = \frac{\mathbb{E}[(Y(1) - Y(0))D]}{\mathbb{P}[D = 1]} = \int \tau(x)\frac{\mathbb{P}[D = 1|X = x]}{\mathbb{P}[D = 1]}\mathbb{P}_X(dx)\,,$$

Proveja uma intuição para esse resultado.

d Proveja uma condição suficiente para que os pesos ω^* sejam não negativos (quase certamente). Mostre que os pesos não serão positivos quase certamente se existir uma entrada X_j de X que toma, para qualquer intervalo da reta, valores nesse intervalo com probabilidade positiva, e tal que $\pi_{*,j} \neq 0$. Mostre que os ω^* serão não negativos se $X = (\mathbf{1}_{\{z_1\}}(Z), \mathbf{1}_{\{z_2\}}(Z), \ldots \mathbf{1}_{\{z_k\}}(Z))'$ onde Z é uma variável aleatória que toma valores no conjunto $\{z_1, \ldots, z_k\}$.