EAE6029

Exercícios sobre Estimação por MQO

No que segue, sempre suponha que as variáveis aleatória relevantes estão definidas no mesmo espaço de probabilidade.

Exercício 1 Seja S um vetor aleatório, e X um conjunto de variáveis aleatórias. Mostre a lei da variância total, i.e:

$$\mathbb{V}[S] = \mathbb{E}[\mathbb{V}[S|X]] + \mathbb{V}[\mathbb{E}[S|X]]\,.$$

Exercício 2 Sejam A e B duas matrizes simétricas positiva definidas de dimensão n. Mostre que, se $A - B$ é positiva semidefinida, então $B^{-1} - A^{-1}$ é positiva semidefinida.

Exercício 3 Considere o seguinte modelo linear para uma amostra de n observações:

$$\boldsymbol{y} = \boldsymbol{X}_1\beta_1 + \boldsymbol{X}_2\beta_2 + \boldsymbol{\epsilon}\,,$$

onde $\mathbb{E}[\boldsymbol{\epsilon}|\boldsymbol{X}_1, \boldsymbol{X}_2] = 0$, $\mathbb{V}[\boldsymbol{\epsilon}|\boldsymbol{X}] = \sigma^2\mathbb{I}_{n\times n}$, $[\boldsymbol{X}_1\ \boldsymbol{X}_2]$ tem posto cheio, e $\boldsymbol{X}_1 = [\boldsymbol{1}_{n\times 1}\ \boldsymbol{Z}]$, onde $\boldsymbol{1}_{n\times 1}$ é um vetor de uns e $\boldsymbol{Z}$ é *independente* de $\boldsymbol{X}_2$. Suponha, ademais, por simplicidade, que $\boldsymbol{X}_2$ é normalizado de tal forma que $\mathbb{E}[\boldsymbol{X}_2|\boldsymbol{Z}] = 0$.

a Mostre que o estimador de MQO de $\boldsymbol{y}$ em $\boldsymbol{X}_1$, denotado por $\tilde{b}_1$, é não viciado (condicionalmente a $\boldsymbol{X}_1$) para β_1.

b Mostre que a variância condicional de $\tilde{b}_1$ se escreve como:

$$\mathbb{V}[\tilde{b}_1|\boldsymbol{X}_1] = (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\mathbb{V}[\boldsymbol{X}_2\beta_2|\boldsymbol{X}_1]\boldsymbol{X}_1'(\boldsymbol{X}_1\boldsymbol{X}_1)^{-1} + \sigma^2(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}$$

c Mostre que a variância do estimador de MQO de β_1 da regressão que inclui $\boldsymbol{X}_1$ e $\boldsymbol{X}_2$, denotado por $\hat{b}_1$, é não viciado para β_1 (condicionalmente a $\boldsymbol{X}_1$ e $\boldsymbol{X}_2$) e que sua variância condicional é dada por:

$$\mathbb{V}[\hat{b}_1|\boldsymbol{X}_1, \boldsymbol{X}_2] = \sigma^2\left(\boldsymbol{X}_1'M_2\boldsymbol{X}_1\right)^{-1}\,,$$

onde M_2 é a residualizadora de $\boldsymbol{X}_2$.

d Mostre que $\left(\boldsymbol{X}_1'M_2\boldsymbol{X}_1\right)^{-1} - (\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}$ é positiva semidefinida.

e Mostre que $(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}\boldsymbol{X}_1'\mathbb{V}[\boldsymbol{X}_2\beta_2]\boldsymbol{X}_1'(\boldsymbol{X}_1'\boldsymbol{X}_1)^{-1}$ é positiva semidefinida.

f Usando a lei da variância total e os dois resultados anteriores, mostre que a diferença entre as variâncias *incondicionais* de $\tilde{b}_1$ e $\hat{b}_1$ se fatoram em dois termos, A e B, em que A é a esperança de uma matriz aleatória positiva semidefinida e B a esparança de uma matriz negativa semidefinida. Proveja uma intuição para esse resultado. Se o interesse reside em β_1, quando fará sentido incluir $\boldsymbol{X}_2$ na regressão?

g Mostre que se $\beta_2 = 0$, então $\mathbb{V}[\hat{\beta}_1] - \mathbb{V}[\tilde{\beta}_1]$ é positiva semidefinida. Esse resultado contradiz o teorema de Gauss-Markov? Por quê?

Exercício 4 Considere um modelo linear da forma:

$$\boldsymbol{y} = \boldsymbol{X}\beta + \boldsymbol{\epsilon}$$

onde $\boldsymbol{y}$ é um vetor aleatório $n \times 1$, $\boldsymbol{X} = \begin{bmatrix} X_1' \\ X_2' \\ \vdots \\ X_n' \end{bmatrix}$ é uma matriz aleatória $n \times k$ e $\boldsymbol{\epsilon}$ é um vetor aleatório de dimensão $n \times 1$. No que segue, vamos supor que $\boldsymbol{X}$ tem posto k (com probabilidade 1), e que a hipótese de exogeneidade $\mathbb{E}[\boldsymbol{\epsilon}|\boldsymbol{X}] = 0$ é satisfeita. Suponha, também, que a matriz de variância (condicional) dos $\boldsymbol{\epsilon}$ seja diagonal (i.e. os erros são condicionalmente não correlacionados), embora potencialmente heterocedástica, i.e.:

$$\mathbb{V}[\boldsymbol{\epsilon}|\boldsymbol{X}] = \begin{bmatrix} \sigma_1^2(\boldsymbol{X}) & 0 & 0 & \dots & 0 \\ 0 & \sigma_2^2(\boldsymbol{X}) & 0 & \dots & 0 \\ \vdots & \vdots & \ddots & \dots & \vdots \\ 0 & 0 & 0 & \dots & \sigma_n^2(\boldsymbol{X}) \end{bmatrix},$$

onde os σ_i^2 são funções desconhecidas de $\boldsymbol{X}$.

a Mostre que a matriz de variância do estimador de MQO de β, denotado por $\hat{b}$ toma a forma:

$$\mathbb{V}[\hat{b}|\boldsymbol{X}] = (\boldsymbol{X}'\boldsymbol{X})^{-1} \left(\sum_{i=1}^{n} X_i X_i' \sigma_i^2(\boldsymbol{X}) \right) (\boldsymbol{X}'\boldsymbol{X})^{-1}$$

b Suponha que a matriz $\boldsymbol{X}$ é robusta a eliminações de uma observação da amostra, no sentido de que as matrizes $(n-1) \times k$ que consistem na remoção da i-ésima linha de $\boldsymbol{X}$ e que denotamos por $\boldsymbol{X}_{-i}$ têm posto k, para todo $i = 1 \dots, n$. Considere o seguinte resíduo modificado:

$$\tilde{e}_i = (Y_i - X_i'\hat{b}_{-i}),$$

onde $\hat{b}_{-i}$ é o estimador de MQO de β na subamostra de $(n-1)$ observações que exclui i. Mostre que (com probabilidade 1):

$$\mathbb{E}[\tilde{e}_i^2|\boldsymbol{X}] \geq \sigma_i^2(\boldsymbol{X}).$$

c Mostre que o resíduo convencional, $\hat{e}_i = Y_i - X_i'\hat{b}$, não necessariamente satisfaz $\mathbb{E}[\hat{e}_i^2|\boldsymbol{X}] \geq \sigma_i^2(\boldsymbol{X})$ com probabilidade 1. Dê uma intuição para esse resultado.

d Com base nos resultados anteriores, construa um estimador $\hat{V}$ para a variância $\mathbb{V}[\hat{b}|\boldsymbol{X}]$ (em média) conservador, no sentido de que (com probabilidade 1):

$$\mathbb{E}[\hat{V}|\boldsymbol{X}] - \mathbb{V}[\hat{b}|\boldsymbol{X}],$$

é positiva semidefinida. Argumente que o estimador *heteroskedasticity-consistent* de White para a variância visto em aula não necessariamente satisfará essa propriedade.

Para o próximo exercício, suponha sempre que as variáveis aleatórias têm variância estritamente positiva e finita.

Exercício 5 Considere variáveis aleatórias Y e D cuja distribuição conjunta representa a distribuição, em uma população de interesse, de um resultado de interesse Y, e uma causa binária (D) cujos efeitos causais desejamos aferir. Defina as variáveis aleatórias $Y(0)$ e $Y(1)$ correspondentes ao experimento hipotético de se amostrar um indivíduo da população e manipular (*ceteris paribus*) a causa binária para 0 ($Y(0)$) e 1 ($Y(1)$), de modo que o resultado observado é dado por $Y = DY(1) + (1 - D)Y(0)$. Vamos supor que D é independente de $(Y(0), Y(1))$, de modo que não há associação sistemática, na população, entre o valor observado da causa binária e os resultados que seriam observados caso o tratamento fosse fixado externamente em 0 ou em 1.

a Mostre que Y pode ser escrito como:

$$Y = \alpha + \beta D + U \,,$$

onde $\beta = \mathbb{E}[Y(1) - Y(0)]$ é o efeito esperado de se amostrar um indivíduo da população e avaliar o efeito da causa D sobre ele; $\mathbb{E}[U] = 0$ e $\text{cov}(D, U) = 0$.

b Mostre que o estimador de MQO do coeficiente associado a D numa regressão de Y num intercepto, com base numa amostra aleatória de (D, Y), é consistente para β. O estimador é não viciado para β? Justifique.

c Mostre que, se não houver heterogeneidade no efeito do tratamento, i.e. $\mathbb{V}[Y(1) - Y(0)] = 0$, então existirá σ^2 tal que a variável aleatória U do modelo definido no item (a) satisfaz: $\mathbb{V}[U|D] = \sigma^2$ (com probabilidade 1).

d Com base no resultado do item anterior e numa amostra aleatória de (D, Y), sugira um teste para a hipótese nula de que não há heterogeneidade no efeito do tratamento, contra a alternativa de que há.

Exercício 6 O arquivo `cps_union_data.csv` conté uma amostra **12.834 indivíduos na força de trabalho norte-americana**, extraída do suplemento anual de 2019 da *Pesquisa de População Atual dos EUA (Current Population Survey)*. Seu objetivo é **estimar o efeito causal da filiação/cobertura sindical** (variável `union`) sobre os **rendimentos semanais** (variável `earnings`). O conjunto de dados contém diversas outras variáveis que podem ser utilizadas como controles (verifique o dicionário do conjunto de dados, disponível em `dictionary.xlsx`).

i Como ponto de partida, compare a **média dos rendimentos** entre os indivíduos com cobertura sindical (`union == 1`) e os indivíduos sem essa cobertura (`union == 0`). Qual é a diferença estimada? Usando um teste t para comparação de médias entre duas populações, teste a hipótese nula de que a remuneração média na população filiada é igual à remuneração média na população não filiada, contra a alternativa bilateral. Você rejeita a hipótese nula a 5% de significância? E a 1%? diferença é estatisticamente significativa? Você acredita que essa diferença é uma estimativa crível do impacto causal da cobertura sindical? Por quê? *Dica:* utilize o comando `t.test` do pacote básico do `R`.

ii Mostre analiticamente que a diferença de médias estimada anteriormente pode ser obtida através de uma regressão de `earnings` em um intercepto e `union`, e que a estatística t do coeficiente associado a `union` baseada em erros padrão robustos à heterocedasticidade é idêntica, a não ser por correção de graus de liberdade, à estatística t utilizada no teste anterior.

iii Para melhorar e/ou avaliar a credibilidade dos seus resultados anteriores, você decide considerar um modelo linear causal da forma:

$$\text{earnings}_i = \beta_0 + \beta_1 \text{union}_i + \gamma' Z_i + \epsilon_{it} \tag{1}$$

onde Z_i representa um conjunto de variáveis de controle.

a) Especifique o modelo linear da Equação (1) apresentando um conjunto de covariáveis Z a serem incluídas como controles. Justifique a escolha dessas variáveis. Qual é a interpretação de β_1 no seu modelo?

b) Estime o modelo especificado. Qual é a sua estimativa de β_1? Usando erros padrão robustos à heterocedasticidade, ela é estatisticamente significativa? Comente brevemente os seus resultados.

c) Usando o teorema de Frisch-Waugh-Lovell, mostre que o estimador de MQO para β_1 tem a seguinte forma:

$$\hat{\beta}_1 = \sum_{i=1}^{N} \text{union}_i \cdot \omega_i \cdot \text{earnings}_i - \sum_{i=1}^{N} (1 - \text{union}_i) \cdot \omega_i \cdot \text{earnings}_i \tag{2}$$

onde os pesos ω_i são definidos como:

$$\omega_i = \frac{\hat{\xi}_i (2 \cdot \text{union}_i - 1)}{\text{SSR}_{\text{union},Z}} \tag{3}$$

com $\hat{\xi}_i$ sendo o resíduo da observação i de uma regressão linear de union_i sobre Z (incluindo intercepto); e $\text{SSR}_{\text{union},Z}$ é a soma dos quadrados dos resíduos dessa regressão auxiliar.

d) Calcule os pesos para sua especificação usando a fórmula acima. Apresente estatísticas descritivas da distribuição dos pesos nos grupos de controle e tratamento.

- Os pesos somam 1 no grupo de controle?
- E no grupo de tratamento?
- Há valores negativos?
- E outliers?

Como esses pesos diferem com relação ao estimador de diferença de médias para o tratamento? Proveja uma intuição para essa diferença.

Para o próximo exercício, suponha sempre que as variáveis aleatórias têm variância estritamente positiva e finita.

Exercício 7 Suponha que você esteja interessado em estudar o efeito de infraestrutura escolar no desempenho escolar médio dos aluno. Você possui acesso a uma amostra aleatória de municípios, para os quais você observa o desempenho escolar médio dos alunos de C escolas, $c = 1, \ldots, C$, em cada um dos M munícipios, $m = 1, \ldots, M$, amostrados ($Y_{c,m}$), e uma medida de conectividade da escola à Internet, em *megabytes por segundo* (mbps) ($X_{c,m}$). Você então postula o seguinte modelo causal linear para $Y_{c,m}$

$$Y_{c,m} = \gamma X_{c,m} + \epsilon_{c,m}\,, \quad c = 1, \ldots, C,\ m = 1, \ldots, M\,,$$

onde γ é o efeito causal de se aumentar a conectivadade da escola em 1mbps sobre o desempenho médio dos alunos, e $\epsilon_{c,m}$ são as demais causas não observadas do desempenho escolar.

a Sob qual condição a inclinação do melhor preditor linear de $Y_{c,m}$ num intercepto e $X_{c,m}$ identifica γ? Você acredita que essa condição seria satisfeita na prática? Por quê?

Em virtude da dificuldade de se acreditar na hipótese anteriormente postulada, um colega seu sugere que você explicitamente acomode a presença de causas não observadas no nível municipal que afetam desempenho municipal, considerando a decomposição:

$$\epsilon_{c,m} = \psi_m + \nu_{c,m} \,,$$

onde ψ_m é um conjunto de causas comuns ao município, e $\nu_{c,m}$ são causas idiossincráticas às escolas. Seu colega lhe diz que é possível levar em conta ("controlar") as causas ψ_m na estimação, mesmo que estas não sejam observadas, considerando uma regressão de $Y_{c,m}$ em $X_{c,m}$ e um conjunto de M *dummies* municipais, i.e. $D_{c,m}(l) = \mathbf{1}_{\{l\}}(m)$, $l = 1 \ldots, m$.

b Usando o teorema de Frisch-Waugh-Lovell, mostre que o estimador do coeficiente de $X_{c,m}$ sugerido pelo seu colega é algebricamente idêntico a se estimar γ a partir de uma regressão (sem intercepto) de $Y_{c,m} - \bar{Y}_m$ em $X_{c,m} - \bar{X}_m$, onde $\bar{Z}_m = \frac{\sum_{i=1}^{C}}{C} Z_{i.m}$. Em outras palavras, o estimador sugeriod pelo seu colega é equivalente ao estimador de MQO do modelo transformado.

$$Y_{c,m} - \bar{Y}_m = \gamma(X_{c,m} - \bar{X}_m) + \epsilon_{c,m} - \bar{\epsilon}_m \,.$$

c Proveja condições suficientes para que o estimador de MQO sugerido seja consistente para o parâmetro de interesse, num regime assintótico em que $M \to \infty$. Qual a interpretação dessas condições?

d Derive a variância assintótica do estimador, sob as hipóteses do item anterior, permitindo que haja correlação arbitrária entre os $\epsilon_{c,m}$ intramunicipais. Sugira um estimador consistente para a variância assintótica.

Exercício 8 O objetivo deste exercício consiste em entender as propriedades do estimador da variância robusta a *cluster*. Para isso, usaremos os dados do resultado da aplicação de um teste lógico em alunos de um conjunto de escolas primárias, disponível em `dados.csv`.

a Construa uma função em `R` que:

1. Sorteie 500 escolas, $c = 1, \ldots, 500$, **com reposição**, do conjunto de dados. Note que haverá escolas repetidas, mas elas serão tratadas como distintas para os fins da simulação (de modo a refletir amostragem aleatória de uma população de escolas).
2. Para cada uma das $c = 1, \ldots, 500$ escolas sorteadas, gere um tratamento fictício no nível escolar, $X_c \sim \text{Uniforme}[0, 1]$, de forma independente entre as escolas e dos dados.
3. Com base na base de dados construída, estime por MQO a especificação linear:

$$\text{logico}_{i,c} = \alpha + \beta X_c + \gamma \text{sexo}_{i,c} + \phi \text{idade}_{i,c} + \epsilon_{i,c} \,,$$

4. Guarde as estatísticas t do teste da hipótese nula de que $\beta = 0$ baseados em erros padrão robustos à heterocedasticidade e a *cluster* no nível da escola.

b Aplique a função 1000 vezes, e calcule a proporção de casos em que cada um dos dois tipos de testes t, a 5% de significância, rejeita a hipótese nula. Se o estimador da variância estiver "correto", qual a proporção esperada de casos em que se rejeita a nula? Por quê? O que você obteve na prática? Por quê?

c Agora adapte a função anterior, permitindo que o tratamento, agora denotado por $\tilde{X}_{i,c} \sim$ Uniforme$[0,1]$, varie no nível individual de forma independente. Aplique a nova função mil vezes. Reporte a proporção de casos em que se rejeitou a hipótese nula. O que ocorreu? Por quê?

d Adapte mais uma vez a função, agora permitindo que o tratamento exerça um efeito heterogêneo entre escolas. Especificamente, você gerará $\widetilde{\texttt{logico}}_{i,c} = \texttt{logico}_{i,c} + \tau_c \tilde{X}_{i,c}$, onde $\tau_c = 1$ com probabilidade 1/2 e -1 com probabilidade 1/2, e independente das demais variáveis. Nós continuaremos rodando a regressão linear de $\tilde{\texttt{logico}}_{i,c}$ em $\tilde{X}_{i,c}$ e controles. Aplique a função nova 1000 vezes. Qual a proporção de casos rejeitados agora? Por quê?

Para o próximo exercício, suponha sempre que as variáveis aleatórias têm variância estritamente positiva e finita.

Exercício 9 Suponha que temos uma amostra $\{(y_{it}, x_{it})_{t=1}^T\}_{i=1}^N$. As observações $(y_{it}, x_{it})_{t=1}^T$ são i.i.d. *entre indivíduos (i)*, mas não impomos restrições sobre a relação entre (y_{it}, x_{it}) ao longo de t para um mesmo i (você pode pensar que selecionamos uma amostra aleatória de N indivíduos, para os quais observamos y e x ao longo de T períodos). Estamos interessados no modelo linear:

$$y_{it} = \beta_0 + \beta_1 x_{it} + \epsilon_{it} \quad \mathbb{E}[\epsilon_{it}] = 0 \quad \mathbb{E}[\epsilon_{it} x_{it}] = 0 \tag{4}$$

a Suponha que $\mathbb{E}[\epsilon_{ik}\epsilon_{il}|x_{ik}, x_{il}] = \sigma^2$ se $k = l$ e $\mathbb{E}[\epsilon_{ik}\epsilon_{il}|x_{ik}, x_{il}] = 0$ caso contrário. Mostre que, para T fixo, quando $N \to \infty$,

$$\sqrt{N}(\hat{\beta}_1^{\text{OLS}} - \beta_1) \xrightarrow{d} N(0, V_1),$$

onde

$$V_1 := \frac{\sigma^2 T^{-1}}{T^{-1}\sum_{t=1}^T \mathbb{E}[x_{it} - T^{-1}\sum_{t=1}^T \mathbb{E}[x_{it}]]^2}.$$

O denominador de V_1 é conhecido como *within-individual variance* de X, que denotamos por τ.

b Agora relaxe a hipótese anterior e suponha que $\mathbb{E}[\epsilon_{ik}\epsilon_{il}|x_{ik}, x_{il}] = \sigma^2$ se $k = l$ e $\mathbb{E}[\epsilon_{ik}\epsilon_{il}|x_{ik}, x_{il}] = \rho\sigma^2$ se $k \neq l$. Mostre que, nesse caso, para T fixo, quando $N \to \infty$,

$$\sqrt{N}(\hat{\beta}_1^{\text{OLS}} - \beta_1) \xrightarrow{d} N(0, V_2),$$

onde

$$V_2 := V_1 (1 + \rho\kappa(T-1))$$

e

$$\kappa := \frac{\sum_{k=1}^T \sum_{l \neq k} \mathbb{E}\left[\left(x_{ik} - T^{-1}\sum_{t=1}^T \mathbb{E}[x_{it}]\right)\left(x_{il} - T^{-1}\sum_{t=1}^T \mathbb{E}[x_{it}]\right)\right]}{T(T-1)\tau}$$

é a correlação intra-indivíduo de x. Em quais casos V_2 é igual a V_1?

c Mostre que, sob as hipóteses de (a), o estimador usual de variância computado sob homocedasticidade estima consistentemente V_1. Sob as hipóteses de (b), você consegue encontrar um estimador consistente para V_2? Mostre sua consistência.

d Agora volte ao item (a) e relaxe a hipótese de homocedasticidade, mantendo ainda que $\mathbb{E}[\epsilon_{ik}\epsilon_{il}|x_{ik}, x_{il}] = 0$ se $k \neq l$. Qual é a variância assintótica (V_3) nesse caso?

e Agora volte ao item (b) e relaxe a hipótese de homocedasticidade na estrutura de covariância. Qual é a variância assintótica (V_4) nesse caso? Em quais situações ela é igual à variância em (d)? Em geral, essas condições são as mesmas do item (b)?

f Mostre que, sob as hipóteses do item (d), o estimador robusto usual de variância estima consistentemente a variância assintótica V_3. Sugira um estimador consistente para V_4 (sob as hipóteses do item (e)). Não é necessário provar sua consistência.

Exercício 10 Neste exercício, vamos estudar o impacto da disponibilidade de água durante o período gestacional sobre os resultados de saúde de recém-nascidos[1]. Mais especificamente, estaremos interessados em como flutuações de chuva durante a gravidez afetam a mortalidade infantil por meio de dois canais: (i) menor produção agrícola e menor ingestão de nutrientes; e (ii) falta de água potável segura e maior incidência de doenças infecciosas.

a Baixe o conjunto de dados `base_clima_datasus2010.dta`. Esse banco de dados contém informações em nível de município sobre variações de precipitação e indicadores de saúde de recém-nascidos. Quantos municípios existem na base? Quantos períodos de dados?

b Para analisar o impacto das variações de chuva sobre a mortalidade infantil, propomos estimar a seguinte especificação linear:

$$\text{infant_mortality}_{mt} = \beta_0 + \beta_1 R_{mt} + \epsilon_{mt} \tag{5}$$

onde $\text{infant_mortality}_{mt}$ denota a taxa de mortalidade infantil (por 1.000 nascimentos) no município m no período t (coluna `k_obt_nasc`) e R_{mt} é um *choque de precipitação*, definido como o desvio logarítmico da precipitação no último ano (períodos $t-11, t-10, \ldots, t$) em relação à sua média histórica anual no município m (coluna `dyang_last12`).

Qual é o coeficiente estimado? O que ele mede e como deve ser interpretado?

c Calcule os estimadores $\hat{V}_1$, $\hat{V}_2$, $\hat{V}_3$, $\hat{V}_4$ do exercício anterior e os respectivos *p-valores* para $\hat{\beta}_1$.

d Você acha que o valor do coeficiente encontrado em (b) fornece uma estimativa crível do efeito causal que queremos analisar? Por quê? Caso a resposta seja negativa, seria possível usar os dados disponíveis para estimar uma especificação alternativa que produza estimativas mais confiáveis? O que você encontrou?

Exercício 11: Aproximação não parámetrica. Considere Y uma variável aleatória real, e X um vetor aleatório de dimensão k, ambos definidos num mesmo espaço de probabilidade $(\Omega, \Sigma, \mathbb{P})$. Seja m a função de esperança condicional de Y em X, i.e. $m(X) = \mathbb{E}[Y|X]$. Dizemos que uma coleção de funções $p_l : \mathbb{R}^k \mapsto \mathbb{R}$, $l \in \mathbb{N}$, aproxima m em $L_2(\mathbb{P}_X)$ se existe uma sequência $\beta_j \in \mathbb{R}^j$, $j \in \mathbb{N}$, tal que:

[1] Este exercício é baseado em Rudi Rocha and Rodrigo R Soares (2015). "Water scarcity and birth outcomes in the Brazilian semiarid". In: *Journal of Development Economics* 112, pp. 72–91.

$$\lim_{j\to\infty}\int (m(x)-\beta_j'\boldsymbol{P}_j(x))^2\mathbb{P}_X(dx)=0$$

com $\boldsymbol{P}_j(x)=(p_1(x),p_2(x),\dots p_j(x))'$, e onde $\mathbb{P}_X$ denota a lei de probabilidade induzida por X.

Seja (X_i,Y_i), $i=1,\dots,n$ uma amostra aleatória de (X,Y). Dada uma coleção $\{p_l\}_{l\in\mathbb{N}}$ que aproxima m em $L_2(\mathbb{P}_X)$, defina, para $J\in\mathbb{N}$, o estimador de MQO de Y_i em $\boldsymbol{P}_J(X_i)$ como:

$$\hat{b}_J=\left(\boldsymbol{Z}_J'\boldsymbol{Z}_J\right)^{-1}\boldsymbol{Z}_J'\boldsymbol{y}\,,$$

onde:

$$\boldsymbol{y}=\begin{pmatrix}Y_1\\ \vdots\\ Y_n\end{pmatrix}$$

e

$$\boldsymbol{Z}_J=\begin{bmatrix}\boldsymbol{P}_J(X_1)'\\ \boldsymbol{P}_J(X_2)'\\ \vdots\\ \boldsymbol{P}_J(X_n)'\end{bmatrix}.$$

No que segue, suporemos sempre que $J\le n$, e que $\left(\boldsymbol{Z}_J'\boldsymbol{Z}_J\right)^{-1}$ existe com probabilidade 1. Além disso, como estaremos interessados nas propriedades do espaço gerado pelas colunas de $\boldsymbol{Z}_J$, vamos supor, sem perda de de generalidade, que $\frac{1}{n}\left(\boldsymbol{Z}_J'\boldsymbol{Z}_J\right)=\mathbb{I}_{J\times J}$.[2]

a Seja $\beta_J\in\mathbb{R}^J$ o J-ésimo elemento da sequência de coeficientes que satisfaz a propriedade de aproximação de m. Mostre que:

$$\|\hat{b}_J-\beta_J\|_2\le\|(\boldsymbol{Z}_J'\boldsymbol{Z}_J)^{-1}\boldsymbol{Z}_J'\left(\boldsymbol{m}-\boldsymbol{Z}_J\beta_J\right)\|_2+\|(\boldsymbol{Z}_J'\boldsymbol{Z}_J)^{-1}\boldsymbol{Z}_J'\boldsymbol{\epsilon}\|_2$$

onde

$$\boldsymbol{m}=\begin{bmatrix}m(X_1)\\ m(X_2)\\ \vdots\\ m(X_n)\end{bmatrix}$$

e

$$\boldsymbol{\epsilon}=\begin{bmatrix}Y_1-m(X_1)\\ Y_2-m(X_2)\\ \vdots\\ Y_n-m(X_n)\end{bmatrix}.$$

Mostre, além disso, que que:

$$\|(\boldsymbol{Z}_J'\boldsymbol{Z}_J)^{-1}\boldsymbol{Z}_J'\left(\boldsymbol{m}-\boldsymbol{Z}_J\beta_J\right)\|_2^2=\frac{1}{n}(\boldsymbol{m}-\boldsymbol{Z}_J\beta_J)'\boldsymbol{\Pi}_J(\boldsymbol{m}-\boldsymbol{Z}_J\beta_J)$$

$$\|(\boldsymbol{Z}_J'\boldsymbol{Z}_J)^{-1}\boldsymbol{Z}_J'\boldsymbol{\epsilon}\|_2^2=\frac{1}{n}\boldsymbol{\epsilon}'\boldsymbol{\Pi}_J\boldsymbol{\epsilon}$$

onde $\boldsymbol{\Pi}_J$ é a matriz de projeção de $\boldsymbol{Z}_J$.

[2] De fato, o espaço gerado pelas colunas de $\boldsymbol{Z}_J$ é igual ao espaço gerado pelas colunas de $\tilde{\boldsymbol{Z}}_J=\sqrt{n}\boldsymbol{Z}_J(\boldsymbol{Z}_J'\boldsymbol{Z}_J)^{-1/2}$.

b Mostre que, se existe C tal que $\mathbb{V}[Y|X] < C$ com probabilidade 1, então, com probabilidade 1:

$$\mathbb{E}\left[\boldsymbol{\epsilon}'\boldsymbol{\Pi}_J\boldsymbol{\epsilon}|\boldsymbol{X}\right] \leq CJ$$

onde $\boldsymbol{X} = [X_1 X_2 \ldots X_n]'$. *Dica:* use a decomposição espectral de uma matriz simétrica.

c Mostre que:

$$\mathbb{E}[(\boldsymbol{m} - \boldsymbol{Z}_J\beta_J)'\boldsymbol{\Pi}_J(\boldsymbol{m} - \boldsymbol{Z}_J\beta_J)] \leq n\mathbb{E}[(m(X) - \beta_J'\boldsymbol{P}_J(X))^2]$$

d Conclua que, sob o limite a $\mathbb{V}[Y|X]$ anterior, se considerarmos uma sequência $(J_n)_{n\in\mathbb{N}}$ tal que, quando $n \to \infty$, $J_n \to \infty$ e $\frac{J_n}{n} \to 0$:

$$\lim_{n\to\infty} \mathbb{E}[\|\hat{b}_{J_n} - \beta_{J_n}\|_2^2] = 0\,.$$

Use a desigualdade de Markov para concluir que $\|\hat{b}_{J_n} - \beta_{J_n}\|_2 \xrightarrow{p} 0$.

e Use os resultados anteriores para concluir que, sob as hipóteses em $\mathbb{V}[Y|X]$ e no crescimento de J_n:

$$\lim_{n\to\infty} \mathbb{E}\left[\int (m(s) - \hat{b}_{J_n}'\boldsymbol{P}_{J_n}(s))^2 \mathbb{P}_X(ds)\right] = 0\,,$$

onde a expectativa de fora se dá com respeito à distribuição do estimador $\hat{b}_{J_n}$ em amostras repetivas. Use a desigualdade de Markov para concluir que:

$$\int (m(s) - \hat{b}_{J_n}'\boldsymbol{P}_{J_n}(s))^2 \mathbb{P}_X(ds) \xrightarrow{p} 0\,.$$

Qual a interpretação desse resultado?

Exercício 12: Implementação computacional Vamos considerar um caso particular do ambiente do item anterior. Especificamente, de agora em diante, consideramos que $X \sim \text{Uniforme}[0,1]$.

a Considere a classe de polinômios, $p_l(x) = x^{l-1}$, $l \in \mathbb{N}$. Use o teorema de Stone-Weierstrass para argumentar que, se m é contínua, $\{p_l\}_{l\in\mathcal{N}}$ exibirára a propriedade de aproximação em $L_2(\mathbb{P}_X)$ para m.

b Vamos especializar ainda mais o ambiente. Consideremos que $m : [0,1] \mapsto \mathbb{R}$ toma a forma:

$$m(x) = \begin{cases} \exp(x) & \text{se } x \leq 0.5 \\ \exp(0.5) + \sin(10\pi(x - 0.5)) & \text{se } x > 0.5 \end{cases}$$

e consideremos que:

$$Y = m(X) + \epsilon, \quad \epsilon \sim \mathcal{N}(0,1)\,,$$

com ϵ independente de X.

Apresente a implementação computacional de uma função que, tomando como argumentos (n, J).

- Simula uma amostra aleatória $(Y_i, X_i) \overset{iid}{\sim} (Y, X)$ de tamanho n.
- Implementa o estimador de MQO de Y_i em $p_l(X_i)$, $l = 1, \dots J$, retornando os coeficientes estimados. Dica: no `R`, o comando *poly* pode ser usado para produzir uma matriz $n \times J$ com os polinômios construídos a partir de um vetor $n \times 1$. A opção `raw = T` já reporta o polinômio devidademente ortogonalizado (i.e. tal que a matriz resultante satisfaça $\boldsymbol{Z}'_J \boldsymbol{Z}_J = \mathbb{I}_{J \times J}$), o que acelera a implementação da estimação por MQO.

c Usando a função apresentada anteriormente, e para as seguintes configurações $(n, J) \in \{100, 200, 500\} \times \{1, 2, \dots, 50\}$, faça as seguintes etapas:

- Aplique a função do item anterior $s = 1, \dots, 1000$ vezes, armazenando as estimativas $\hat{b}_{n,J}(s)$, $s = 1, \dots, 1000$.
- Aproxime a quantidade

$$\psi(n, J) = \mathbb{E}\left[\int (m(x) - \hat{b}'_{n,J} \boldsymbol{P}_J(x))^2 \mathbb{P}_X(dx)\right]$$

por:

$$\widetilde{\psi(n, J)} = \frac{1}{1000} \sum_{s=1}^{1000} \frac{1}{501} \sum_{i=0}^{500} \left(m\left(\frac{i}{500}\right) - P_J\left(\frac{i}{500}\right)' \hat{b}_{n,J}(s) \right)^2$$

Produza um gráfico em que, para cada valor de n, você esboce uma curva de como $\widetilde{\psi(n, J)}$ varia com J

d Para cada n, em que valor a curva $J \mapsto \widetilde{\psi(n, J)}$ atinge o ponto mínimo? Qual a relação entre esses pontos de mínimo? Com base nas propriedades do estimador de MQO, proveja uma intuição para esse resultado.