EAE6029

Exercícios sobre Variáveis Instrumentais

No que segue, sempre suponha que as variáveis aleatória relevantes estão definidas no mesmo espaço de probabilidade.

Exercício 1 (Uma equivalência algébrica) Mostre que o estimador de Wald visto em aula para a estimação de um efeito causal de uma variável escalar X sobre um resultado Y, usando como instrumento uma variável escalar Z, é **numericamente idêntico** ao coeficiente estimado de X no estimador de MQO em dois estágios que instrumenta um intercepto e X com base num intercepto e em Z.

Para os próximos exercícios, suponha sempre que as variáveis aleatórias têm variância estritamente positiva e finita.

Exercício 2 (Erro de medida) Considere um modelo causal linear da forma:

$$Y = X^*\beta + U\,,$$

onde X^* é uma causa escalar de interesse, U são as demais causas de um fenômeno, e β é um efeito causal de interesse.

Suponha que o pesquisador não observe X^*, mas somente uma medida ruidosa $X = X^* + V$ de X^*, onde o erro de medida V é tal que $\text{cov}(V, X^*) = 0$ e $\text{cov}(V, U) = 0$. Suponha, ademais que $\text{cov}(X^*, U)$.

a Considere o estimador de MQO de Y num intercepto e X, baseado numa amostra aleatória de (Y, X). Mostre que o estimador de MQO do coeficiente associado a X **não** é consistente para β. Encontre o limite em probabilidade desse estimador. Qual é sua relação com β?

b Suponha que você também observe uma segunda medida ruidosa de X^*, $Z = X^* + \xi$, onde $\text{cov}(\xi, X^*) = 0$, $\text{cov}(\xi, U) = 0$ e $\text{cov}(\xi, V) = 0$. Sugira um estimador consistente para β. Justifique. Se o seu interesse reside em fazer previsões de Y com base nas medidas observáveis de X^* para novas observações fora de sua amostra, faz sentido usar esse estimador? Justifique.

Exercício 3 (Instrumentos fracos) Considere um modelo causal linear da forma:

$$Y = X\beta + U\,,$$

onde X é uma causa escalar de interesse, U são as demais causas de um fenômeno, e β é um efeito causal de interesse. Su

a Calcule o limite de probabilidade do estimador de MQO baseado em uma amostra aleatória de (X, Y).

b Suponha, agora, que tenhamos acesso a um instrumento Z relevante, mas não necessariamente válido. Calcule o limite de probabilidade do estimador de Wald baseado em uma amostra aleatória de (X, Y, Z). Sob quais condições sobre $\text{cor}(X, U)$, $\text{cor}(X, Z)$ e $\text{cor}(Z, U)$, temos que $|\operatorname{plim} \hat{\beta}_{IV} - \beta| > |\operatorname{plim} \hat{\beta}_{MQO} - \beta|$? Discuta seus resultados.

c Suponha agora, que a relação de primeiro estágio entre X e Z é dada, numa amostra aleatória de tamanho n, por um modelo preditivo linear da forma:

$$X = \gamma_n Z + V\,, \quad \text{cov}(Z, V) = 0$$

onde $\gamma_n = C/\sqrt{n}$ para algum $C \neq 0$. A ideia é capturar uma situação em que a relevância do instrumento é da ordem da incerteza amostral.

Suponha que Z é válido, i.e. $\text{cov}(Z, U) = 0$. Mostre que:

$$\hat{\beta}_{IV} \xrightarrow{d} \beta + \frac{N_1}{C\mathbb{V}[Z] + N_2}\,,$$

onde

$$\begin{pmatrix} N_1 \\ N_2 \end{pmatrix} \sim \mathcal{N}\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} \mathbb{E}[(Z - \mathbb{E}[Z])^2 (U - \mathbb{E}[U])^2] & \mathbb{E}[(Z - \mathbb{E}[Z])^2 (U - \mathbb{E}[U])(V - \mathbb{E}[V])] \\ \mathbb{E}[(Z - \mathbb{E}[V])^2 (U - \mathbb{E}[U])(V - \mathbb{E}[V])] & \mathbb{E}[(Z - \mathbb{E}[Z])^2 (V - \mathbb{E}[V])^2] \end{bmatrix} \right)\,,$$

Conclua que o estimador de variáveis instrumentais, nesse caso, é inconsistente. Mostre que, nesse mesmo regime assintótico, temos que:

$$\hat{\beta}_{MQO} \xrightarrow{p} \beta + \theta\,,$$

onde $\theta = \frac{\text{cov}(U,V)}{\mathbb{V}[V]}$.

Para os próximos dois itens, vamos considerar o regime assintótico do item (c), e, ademais, supor as condições de homocedasticidade:

$$\mathbb{E}[(Z - \mathbb{E}[Z])^2 (U - \mathbb{E}[U])(V - \mathbb{E}[V])] = \mathbb{V}[Z]\,\text{cov}(U, Z)\,.$$

$$\mathbb{E}[(Z - \mathbb{E}[Z])^2 (V - \mathbb{E}[V])^2] = \mathbb{V}[Z]\mathbb{V}[V]$$

d Seja $f : \mathbb{R}^2 \mapsto \mathbb{R}$ a função dada por $f(x) = \frac{x_1}{x_2}$. Para uma sequência de vetores aleatórios $\boldsymbol{S}_n$ com valores em $\mathbb{R}^2$ em que a média da variável aleatória na segunda posição é diferente de zero e em que $\|\boldsymbol{S}_n - \mathbb{E}[\boldsymbol{S}_n]\| = O_p(n^{-1/2})$, use a expansão de Taylor de segunda ordem:

$$f(\boldsymbol{S}_N) - f(\mathbb{E}[\boldsymbol{S}_N]) \approx \nabla_x f(\mathbb{E}[\boldsymbol{S}_N])(S_n - \mathbb{E}[\boldsymbol{S}_n]) + \frac{1}{2}(S_n - \mathbb{E}[\boldsymbol{S}_n])' H(f; \mathbb{E}[\boldsymbol{S}_n])(S_n - \mathbb{E}[\boldsymbol{S}_n]) + o_p(n^{-1})\,,$$

e a aproximação resultante para a esperança:[1]

$$\mathbb{E}[f(\boldsymbol{S}_n) - f(\mathbb{E}[\boldsymbol{S}_n])] = +\frac{1}{2}\mathbb{E}[(S_n - \mathbb{E}[\boldsymbol{S}_n])' H(f; \mathbb{E}[\boldsymbol{S}_n])(S_n - \mathbb{E}[\boldsymbol{S}_n])] + o(n^{-1})\,,$$

[1] Essa aproximação é conhecida na literatura como expansão de Nagar do viés de um estimador. Ela implicitamente supõe que o erro $R_n = o_p(n^{-1})$ da expansão de Taylor acima é tal que $\mathbb{E}[R_n] = o(n^{-1})$. Condições suficientes para que isso seja verdade estão fora do escopo desse curso.

para aproximar, no regime assintótico de (c), o viés do estimador de variável instrumental por:

$$\mathbb{E}[\hat{\beta}_{IV}] - \beta = -\theta \frac{\mathbb{V}[V]}{C^2 \mathbb{V}[Z]} + o(n^{-1})$$

e Considere a estatística t de primeiro estágio, calculada sob homocedasticidade, i.e.

$$\hat{t} = \frac{\sum_{i=1}^{n}(X_i - \bar{X})(Z_i - \bar{Z})}{\hat{\sigma}_V \sqrt{\sum_{i=1}^{n}(Z_i - \bar{Z})^2}} .$$

Mostre que:

$$\hat{t} \xrightarrow{d} \mathcal{N}\left(\frac{C\,\mathrm{sd}(V)}{\mathrm{sd}(Z)}, 1\right) .$$

Calcule a distribuição assintótica da estatística $\hat{F} = \hat{t}^2$.

f Com base na estatística $\hat{F}$, proponha um teste assintoticamente correto, ao nível de significância de 5%, da hipótese nula de que o viés assintótico do estimador de IV é no máximo 10% do "viés assintótico" do estimador de MQO, i.e., queremos testar

$$H_0 : \frac{|\lim_{n\to\infty} \mathbb{E}[\hat{\beta}_{IV}] - \beta|}{|\operatorname{plim}_n \hat{\beta}_{MQO} - \beta|} \leq 0.1 ,$$

contra a alternativa de que o viés relativo é maior que 10%.

Exercício 4 (Mercado de Peixe Fulton) Considere o seguinte modelo causal linear para descrever as curvas de oferta e demanda no período t em um mercado:

$$\log(D_t(p)) = \psi \log(p) + \epsilon_t^D ,$$

$$\log(S_t(p)) = \gamma \log(p) + \delta' Z_t + \epsilon_t^S ,$$

onde ψ é a elasticidade-preço da demanda, e ϵ_t^D descrevem *shifters* não observáveis da curva de demanda no mercado no período t. De forma análoga, γ denota a elasticidade-preço da curva de demanda, ϵ_t^S denotam *shifters* não observáveis da curvam oferta, e Z_t são shifters observáveis da curva de oferta que sabemos não exibirem associação sistemática com os *shifters* da demanda, i.e. $\mathrm{cov}(Z_t, \epsilon_t^S) = 0$.

a Suponha que os preços e quantidades vendidas (P_t, Q_t) em cada instante de tempo t seja determinado pelo cruzamento das curvas de oferta e demanda, i.e.

$$Q_t = S_t(P_t) = D_t(P_t) .$$

Mostre que, se for este o caso, o melhor preditor linear de $\log(Q_t)$ num intercepto e em $\log(P_T)$ não identificará a elasticidade ψ, e que a inclusão de Z_t na predição linear também não garante a identificação.

b Proponha uma estratégia de variável instrumental para identificar ψ e demonstre a consistência do estimador resultante, baseado em uma amostra aleatória dos mercados ao longo de T períodos.

c Com base nos dados do mercado de peixe Fulton (Graddy, 2006), disponíveis na subpasta `dados`, proponha uma estratégia de variável instrumental para identificar a elasticidade da demanda nesse contexto. Implemente a estimação dessa estratégia. Com base em um nível de significância de 5%, o instrumento é relevante? Você rejeita a hipótese nula de que a demanda tem elasticidade -1? *Observação:* no `R`, use o pacote `fixest` para implementar a estratégia com erros padrão robustos a heterocedasticidade.

Exercício 5 (*Eminent Domain*) Neste exercício, vamos estudar o impacto do *eminent domain* sobre os preços de imóveis nos Estados Unidos[2]. *Eminent domain* (ou leis de desapropriação) é o mecanismo legal pelo qual o governo pode adquirir compulsoriamente uma propriedade privada. Esse tipo de ação é bastante controverso, e os proprietários podem recorrer à Justiça para tentar reverter a decisão. Quando tribunais federais decidem que uma desapropriação foi ilegal (*decisões favoráveis ao autor*, *pro-plaintiff*), os direitos de propriedade são reforçados e cria-se um precedente que torna mais difícil a utilização futura do *eminent domain*. Nosso objetivo será analisar o efeito causal dessas decisões favoráveis ao autor, proferidas nos tribunais federais de apelação, sobre os preços de imóveis.[3]

a Importe `temp_CSHomePrice.mat.csv`. Esse conjunto de dados contém informações sobre preços de imóveis (índice Case-Shiller) e decisões favoráveis ao autor por circuito judicial e período. Observe que, com exceção do índice Case-Shiller em log, todas as variáveis estão em frequência anual. Agregue os dados por ano, calculando a média *dentro de cada circuito-ano* do log do índice de preços.

b Estime uma especificação linear por MQO do log do índice de preços em um intercepto e no número total de decisões de desapropriação em apelação favoráveis ao autor (`numpro_casecat_12`). O que você encontra? Esse coeficiente pode ser interpretado como uma estimativa de um efeito causal? Por quê?

Para lidar com possíveis problemas de endogeneidade, Chen e Yeh (2015) exploram o fato de que, nos tribunais federais de apelação, os juízes são *designados aleatoriamente* para compor painéis de três juízes que decidem os casos. Cada caso recebe três juízes sorteados de um conjunto (*pool*) de magistrados do circuito, que varia aproximadamente entre 8 e 40 dependendo do tamanho do tribunal. Assim, *condicionalmente às características desse conjunto de juízes*, as características observadas dos painéis sorteados devem satisfazer a restrição de exclusão, pois só podem afetar os preços dos imóveis por meio das decisões judiciais.

c Faça o *merge* do conjunto de dados `probs.txt` com sua base. Esse arquivo contém a distribuição das características dos juízes em cada circuito entre 1945 e 2007.

[2]Este exercício é baseado em Chen and Yeh, 2015.

[3]"Uma compreensão básica do funcionamento dos tribunais federais dos EUA é importante para entender nossa estratégia de identificação, que se baseia na função de criação de precedentes dos tribunais de *common law*. As decisões judiciais em casos atuais se tornam precedentes que podem ser utilizados em casos futuros no mesmo tribunal e em tribunais inferiores da mesma jurisdição. Existem três níveis de tribunais federais: Distrito, Circuito e a Suprema Corte dos EUA. Os 94 Tribunais Distritais funcionam como tribunais de primeira instância, onde um júri decide *questões de fato*. Caso uma das partes recorra da decisão, o caso segue para um Tribunal de Circuito, que decide *questões de direito*; esses tribunais tomam os fatos estabelecidos no Tribunal Distrital como dados e não utilizam júri. Os 12 Tribunais de Circuito, também conhecidos como Tribunais de Apelação, analisam apenas casos que levantam novas questões jurídicas (apenas 10–20% das decisões dos tribunais distritais são objeto de recurso). Os casos que chegam aos tribunais de circuito costumam ser os mais complexos e controversos, com maior probabilidade de estabelecer novos precedentes." (Chen e Yeh, p. 11–12).

d Considere o seguinte modelo linear causal:

$$\ln(\text{Case_Shiller})_{ct} = \beta_0 + \beta_1 \text{numpro_casecat_12}_{ct} + \gamma' W_{ct} + \epsilon_{ct}\,, \tag{1}$$

onde W_{ct} inclui o conjunto completo de controles para as características do pool de juízes[4]; uma variável indicadora para os casos em que não houve processos naquele circuito-ano (`missing_cy_12`); e o número total de decisões de apelação envolvendo desapropriações (`numcasecat_12`). Como instrumento, utilizaremos o número de painéis com *pelo menos um juiz Democrata* (`numpanels1x_dem`)[5].

Estime o modelo acima utilizando o instrumento proposto. O instrumento satisfaz a condição de *relevância*? Comente os resultados obtidos.

e Você considera que o coeficiente estimado em (d) fornece uma estimativa *crível do efeito causal* que queremos analisar? Por quê? Caso considere que não, seria possível utilizar os dados disponíveis para estimar uma *especificação alternativa* que produza estimativas mais confiáveis? O que você encontrou?

Exercício 6 (Interpretação Causal com Controles)

Exercício 7 (Tratamentos ordenados)

Exercício 8 (*Trade-off* quantidade-qualidade de filhos) Seu objetivo é entender como a decisão de ter mais filhos impacta a alocação de recursos na educação do primeiro filho. A literatura de economia da família descreve um *tradeoff* entre qualidade e quantidade na decisão de reprodução: ao escolherem ter mais filhos, famílias tendem a alocar menos recursos na educação dos filhos mais velhos. Seu objetivo é testar essa hipótese. Para isso, você se baseia em Ponczek and Souza (2012) e usa dados familiares extraídos do censo brasileiro de 2010. Esses dados estão disponíveis em `censo_data_family_size.csv`. Cada observação da base corresponde ao primeiro filho de uma família brasileira amostrada (famílias cujos primeiros filhos são gêmeos correspondem a mais de uma observação). Um dicionário com a descrição das variáveis da base está disponíbel em `dicionario.xlsx`.

1. Carregue os dados. Restrinja a base aos primeiros filhos de famílias com mais de um parto (`family_number_births` ≥ 2). Qual é o tamanho familiar médio das famílias dos primeiros filhos? ***Dica:*** *Instale o pacote* `data.table` *e use a função* `fread` *para carregar os dados mais rapidamente.*

[5] A justificativa *a priori* dos autores para essa escolha baseia-se em evidências de que juízes Democratas tendem a ser mais favoráveis aos proprietários em casos de *eminent domain*.

[5] A lista completa de controles para características do pool judicial é: prob_1x_dem, prob_2x_dem, prob_3x_dem, prob_1x_female, prob_2x_female, prob_3x_female, prob_1x_nonwhite, prob_2x_nonwhite, prob_3x_nonwhite, prob_1x_black, prob_2x_black, prob_3x_black, prob_1x_jewish, prob_2x_jewish, prob_3x_jewish, prob_1x_catholic, prob_2x_catholic, prob_3x_catholic, prob_1x_noreligion, prob_2x_noreligion, prob_3x_noreligion, prob_1x_instate_ba, prob_2x_instate_ba, prob_3x_instate_ba, prob_1x_ba_public, prob_2x_ba_public, prob_3x_ba_public, prob_1x_jd_public, prob_2x_jd_public, prob_3x_jd_public, prob_1x_elev, prob_2x_elev, prob_3x_elev, prob_1x_female_black, prob_2x_female_black, prob_3x_female_black, prob_1x_female_noreligion, prob_2x_female_noreligion, prob_3x_female_noreligion, prob_1x_black_noreligion, prob_2x_black_noreligion, prob_3x_black_noreligion, prob_1x_female_jd_public, prob_2x_female_jd_public, prob_3x_female_jd_public, prob_1x_black_jd_public, prob_2x_black_jd_public, prob_3x_black_jd_public, prob_1x_noreligion_jd_public, prob_2x_noreligion_jd_public, prob_3x_noreligion_jd_public, prob_1x_mainline, prob_2x_mainline, prob_3x_mainline, prob_1x_evangelical, prob_2x_evangelical, prob_3x_evangelical, prob_1x_protestant, prob_2x_protestant, prob_3x_protestant.

2. Para avaliar a relação prevista pela teoria econômica, você ajusta a seguinte especificação linear por MQO:

$$\texttt{first_child_years_of_education}_i = \beta_0 + \beta_1 \cdot \texttt{family_number_children}_i + \epsilon_i$$

   Qual a interpretação da estimativa obtida? Ela é estatisticamente significante a 5%?

3. Você acredita que a estimativa obtida no item anterior é crível para o efeito que se procura estimar? Por quê?

   Como forma de mitigar as preocupações com a estimação obtida anteriormente, você se propõe a estimar o efeito de se ter mais filhos sobre a educação do primeiro filho instrumentando `family_number_children` com `second_birth_ismultiplebirth`, uma variável binária que é igual a 1 se o segundo parto da família foi de mais de uma criança (gêmeos, trigêmeos etc.).

4. Quantos segundos partos na base são partos de múltiplas crianças?

5. Sob quais conjuntos de hipóteses a metodologia de variáveis instrumentais recupera um efeito causal de interesse, nos seguintes casos: (i) a resposta ao *trade-off* educação e qualidade é homogênea na população; (2) a resposta ao *trade-off* educação e qualidade é heterogênea na população. Quais são os efeitos causais identificados em cada um dos casos? Você consegue pensar em violações dessas hipóteses?

6. Rode o primeiro estágio da metodologia de variáveis instrumentais. Qual a interepretação dos coeficientes obtidos? O instrumento é **relevante**, a 5% de significância?

7. Rode o segundo estágio. Qual a interpretação do coeficiente obtido? Ele é estatisticamente significante a 5%? *Observação:* você deve implementar erros padrão com cluster no nível da família (por quê?).

8. Devido ao padrão de amostragem, sabemos que cada indivíduo na amostra é representativo de `person_weight` indivíduos na população. Reestime os modelos usando essa variável como peso. Os resultados mudam?

References

Chen, Daniel L and Susan Yeh (2015). "Growth Under the Shadow of Expropriation? The Economic Impacts of Eminent Domain".

Graddy, Kathryn (2006). "Markets: The Fulton Fish Market". In: *The Journal of Economic Perspectives* 20.2, pp. 207–220. ISSN: 08953309. URL: `http://www.jstor.org/stable/30033657` (visited on 03/05/2026).

Ponczek, Vladimir and Andre Portela Souza (2012). "New Evidence of the Causal Effect of Family Size on Child Quality in a Developing Country". In: *Journal of Human Resources* 47.1, pp. 64–106. ISSN: 0022-166X. DOI: `10.3368/jhr.47.1.64`. eprint: `https://jhr.uwpress.org/content/47/1/64.full.pdf`. URL: `https://jhr.uwpress.org/content/47/1/64`.